



Visión por Computadora II

Trabajo práctico integrador

Integrantes:



- Marco Joel Isidro
- Diego Sarina

Profesores:

- Juan Ignacio Cavalieri
- Juan Ignacio Cornet
- Pakdaman Seyed

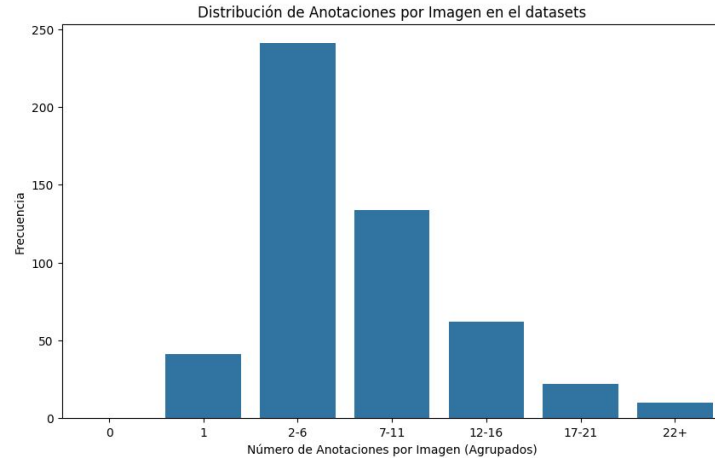
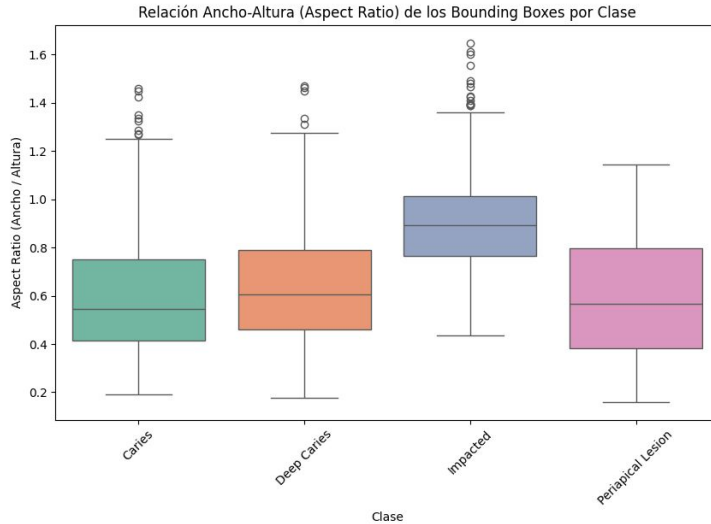

Introducción

- **Objetivo:** Poder detectar diferentes patologías que existen en los dientes a partir de una radiografía panorámica dental.
- **Dataset:**
 - DENTEX CHALLENGE 2023 ([kaggle.com](https://kaggle.com/datasets/med4life/dentex-challenge-2023))
 - +750 radiografías panorámicas de personas mayores de 12 años.
- **Tarea de detección de objetos**



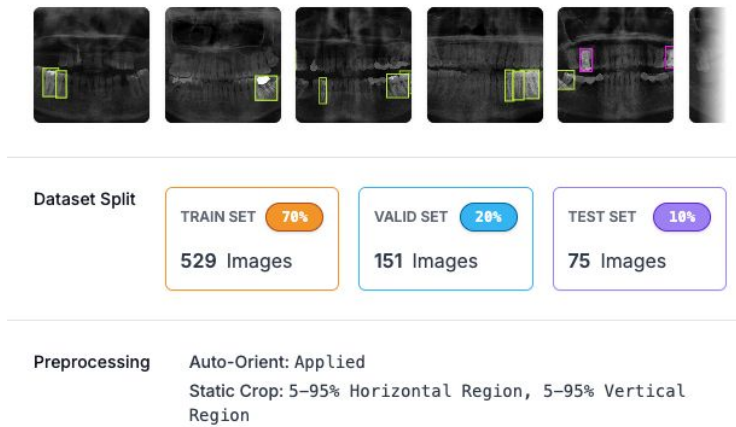
Análisis exploratorio

- Se observa un desbalance de clases pronunciado.
- Múltiples anotaciones por imágenes.
- Aspect Ratio significativo en dientes impactados.



Armado del dataset

- Utilización de la Plataforma Roboflow
 - 70 train
 - 20 valid
 - 10 test
- Preprocesamiento (orientación, corte de imagen)



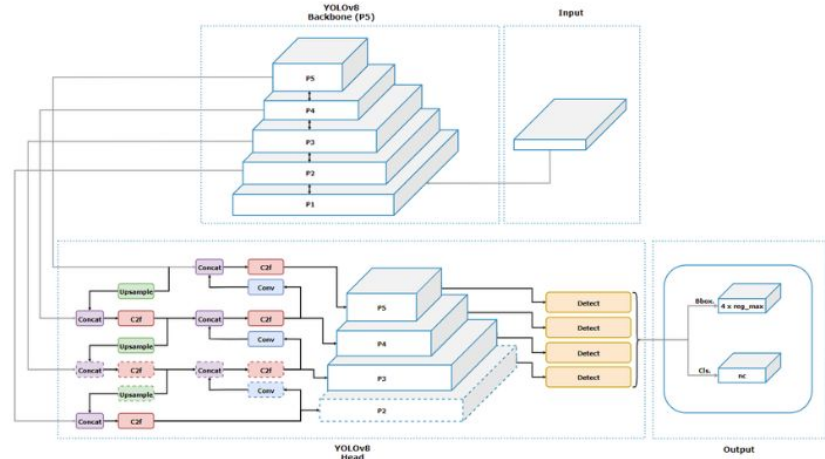


Métricas de evaluación

- Vamos a evaluar la performance del mismo con:
 - AP (Average Precision)
 - mAP 50 (Mean Average Precision)
 - F1-Score


Arquitecturas entrenadas

- YOLO V8
- RetinaNet



Entrenamiento inicial con YOLOv8


- **Parámetros de entrenamiento:**
 - ~100 épocas promedio
 - Dropout
 - Optimizador ADAM
 - 640px imagen
- Score a través de varias clases muy bajo
- Buena predicción para dientes Impactados únicamente



Class	Images	Instances	Box(P	R	mAP50
all	151	709	0.608	0.438	0.398
Caries	128	447	0.347	0.499	0.345
Deep Caries	69	126	0.365	0.317	0.308
Impacted	48	106	0.719	0.934	0.903
Periapical Lesion	23	30	1	0	0.0368


¿Cómo mejorar el modelo?

- Soluciones planteadas en el momento:
 - Data augmentation
 - Probar varias combinaciones posibles de la arquitectura YOLO (otros modelos, hiperparámetros, etc ...)
 - Probar otra arquitectura



Data Augmentation

- Trabajamos con un dataset aumentado de 1800 imágenes
- Esta fue la mejor métrica que obtuvimos y fue con un modelo YOLO-S (Mejóro sustancialmente el modelo) (9,829,599 parameter)
- Se mantiene la confianza alcanzada por el diente impactado




¿Entonces, éxito?



Class	Images	Instances	Box(P	R	mAP50
all	151	709	0.467	0.564	0.497
Caries	128	447	0.351	0.62	0.404
Deep Caries	69	126	0.464	0.579	0.557
Impacted	48	106	0.677	0.991	0.956
Periapical Lesion	23	30	0.377	0.0667	0.0706

Dataset inspection


- Tenemos buenos datos?
- Mis datos son representativos del problema que quiero resolver? ¿Está bien etiquetado?
- Inspeccionemos ...




Dataset original



Dataset modificado







Dataset original



Dataset modificado


Dataset inspection

- Etiquetas superpuestas
- Asignación de zonas incorrectas
- Etc.



Entrenamiento YOLOv8 (dataset nuevo)

- **Parámetros de entrenamiento:**
 - **Mismos que el anterior**
- **Todas las clases aumentaron el nivel de confianza**
- **Posibilidad de seguir mejorando la clase de “caries”**



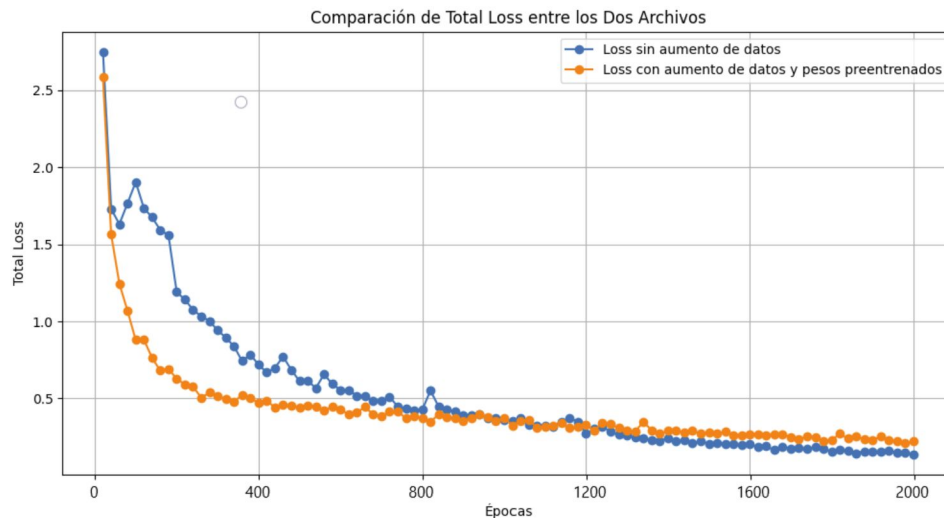
Class	Images	Instances	Box(P	R	mAP50
all	161	869	0.811	0.805	0.838
caries	100	271	0.638	0.395	0.508
corona	50	290	0.893	0.969	0.973
diente impactado	44	88	0.734	0.807	0.835
endodoncia	85	211	0.835	0.853	0.877
implante	3	9	0.956	1	0.995

Arquitectura RetinaNet

- Del mismo tipo que YOLO (redes de una etapa)
- Ideal para datasets con desequilibrio de clases, como radiografías donde algunas patologías son menos comunes (focal loss)
- Permite una mejor detección de objetos a diferentes escalas, como dientes de diversos tamaños (FPN)
- La utilización de aumento de datos y pesos pre entrenados, lograron un entrenamiento más rápido y estable.


```
cfg.SOLVER.IMS_PER_BATCH = 16
cfg.SOLVER.BASE_LR = 0.005
cfg.SOLVER.MAX_ITER = 2000
cfg.MODEL.RETINANET.BATCH_SIZE_PER_IMAGE = 256
```

Métrica	Primer Entrenamiento	Segundo Entrenamiento
AP-caries	28.81	33.71
AP-corona	57.05	57.85
AP-diente impactado	56.40	54.83
AP-endodoncia	36.65	44.49
AP-implante	42.19	58.55
mAP50	78.49	85.69
mAP75	48.19	48.49




Inferencia de los modelos (YOLOv8)


Anotaciones Verdaderas




Predicciones del Modelo



Anotaciones Verdaderas



Predicciones del Modelo



Inferencia de los modelos (RetinaNet)

Imagen Original con etiquetas







Imagen Original con etiquetas



Predicción




Predicción



Conclusiones

- Importancia de la Calidad de los Datos
- Data Augmentation es clave
- YOLOv8 y RetinaNet:
- Desafíos en clases específicas





Visión por Computadora II

¡Gracias!

Integrantes:

- Marco Joel Isidro
- Diego Sarina